

在中文 C-Eval 上用推理步骤遗忘测量 CoT 忠实度

Qwen3-8B 与 Qwen3-4B 的三组 FUR 实验分析

复现实验报告

2026 年 5 月 27 日

摘要

本文在中文 C-Eval 多项选择题上复现 Tutek 等人提出的 *Faithfulness by Unlearning Reasoning Steps* (FUR)，分析一组 Qwen3-8B 实验和两组 Qwen3-4B 实验。特别地，第二组 4B 输出不是同配置重复：它使用 $n = 220$ 个生成 CoT，并将单步骤遗忘从论文标准的 5 个 epoch 延长到 10 个 epoch。统一取前 5 个 epoch 比较时，Qwen3-4B ($n = 250$) 的平均 efficacy 为 74.81，Qwen3-8B 为 63.12；两者在论文协议可比子集上的 FF-HARD 分别为 8.47% 和 7.92%。对 $n = 220$ 延长组，终点从 epoch 5 推进至 epoch 10 后 efficacy 从 88.99 上升到 90.25、全量终点 FF-HARD 从 11.00% 上升到 12.00%。因此，4B 的遗忘干预更强，但延长组的额外忠实度证据必须解释为训练预算变化与样本变化的合并效果，而不是纯粹的模型规模差异。

1 研究背景与复现目标

原论文 *Measuring Chain of Thought Faithfulness by Unlearning Reasoning Steps* 提出参数忠实度框架 (PFF)：若模型生成的某一步推理确实反映了得到答案所依赖的内部计算，则从参数中遗忘该步骤后，直接作答的预测应更容易改变。论文以 FUR 实例化这一框架：将 CoT 分成句子，对每个句子单独施加 NPO+KL 遗忘，并在不重新给模型该 CoT 的 direct-answer 分布上测量答案变化。

本文考察该思想从英文 MCQA 与 LLaMA/Mistral/Phi 模型迁移至中文设置后的表现：数据集改为 C-Eval 验证集，模型改为 Qwen3-8B 与 Qwen3-4B，并使用可见中文 CoT。现有仓库曾仅汇总 8B 结果；本报告将新增的两份 4B 完整输出纳入同一分析，尤其区分标准 5-epoch 结果和 10-epoch 扩展干预。

2 方法与指标

2.1 干预配置

三组运行都使用 npo_KL、sentencize、逐步骤遗忘、学习率 10^{-5} 、随机种子 1001，并仅优化 MLP 的 down_proj.weight (FF2)。每组从生成 CoT 中留出 20 道题用于 specificity，其余题逐句干预。与原论文存在两点实现差异：

- Qwen 使用关闭 thinking 的中文可见推理，并按中文标点进行步骤切分。
- 输出文件标明 pos=False；因此中文复现没有使用原文英语 spaCy 的 content-word POS 过滤，而是针对步骤文本实施遗忘。

表 1: 三组输出的完整性审计。可比题指初始 direct 与 CoT 预测一致的题目。

模型	CoT 数	目标题	步骤数	Epoch	可比题
Qwen3-8B	250	230	498	5	202
Qwen3-4B	250	230	344	5	177
Qwen3-4B	220	200	299	10	154

完整性审计表显示，三份结果分别覆盖预期的 $250 - 20 = 230$ 与 $220 - 20 = 200$ 个目标题，且没有重复步骤或缺失评估 epoch。其中 Qwen3-4B $n = 220$ 的每个步骤含 checkpoint $0, \dots, 10$ ，另外两组均为 $0, \dots, 5$ 。这项差异不是记录噪声，而是本报告单列分析的干预强度变量。

2.2 指标口径

按照论文定义，目标推理步骤 r_i 的遗忘有效性为

$$E_i = \frac{p_M(r_i) - p_{M_i^*}(r_i)}{p_M(r_i)} \times 100,$$

其中 M_i^* 是只遗忘第 i 个步骤后的模型。Specificity 是 held-out 20 题上，干预前后直接预测标签不变的比例。本文的“轨迹”表将 Eff 和 Spec 在干预后 checkpoint (epoch 1 至 5) 以及所有步骤上平均；这与只读取最后 checkpoint 的旧 8B 摘要口径不同，后者另列于表 4。

论文协议中的硬忠实度首先保留初始 direct-answer 与 CoT-conditioned answer 一致的题目，再定义

$$\text{FF-HARD} = \mathbb{K} \left[\exists r_i, \exists e : y_M \neq y_{M_{i,e}^*} \right].$$

即任一推理步骤在观察到的遗忘轨迹中导致直接答案翻转，该题即提供硬忠实度证据。Step FF 是相同条件下发生过翻转的步骤比例。软指标采用论文的答案概率质量变化

$$\text{FF-SOFT}_{i,e} = p(y_M | M) - p(y_M | M_{i,e}^*),$$

表中 *Max FF-SOFT* 为每题最显著步骤/epoch 的移出质量均值，以百分点表示。

3 统一五轮干预预算下的比较

表 2 是最接近论文标准设置的主比较：两份 $n = 250$ 输出具有相同问题规模和 5 epoch 预算； $n = 220$, $E = 10$ 组仅截取它的 epoch 1–5 作为辅助参照，因为其采样题目及步骤集合已经变化。

表 2: 统一 5 epoch 预算下的论文式比较。Eff/Spec 使用全部步骤；忠实度只使用初始预测一致的题目。

实验	Eff	Spec	FF-HARD	Step FF	Max FF-SOFT
Qwen3-8B	63.12	96.78	7.92%	4.68%	6.59
Qwen3-4B	74.81	98.54	8.47%	7.01%	7.19
Qwen3-4B ($n = 220$, 截至 E5)	79.70	97.94	11.69%	9.32%	9.05

在严格可直接比较的两组 $n = 250$ 中，4B 的 Eff 比 8B 高 11.69 个百分点 (74.81 对 63.12)，Spec 同时高 1.76 点 (98.54 对 96.78)。这说明相同学习率与更新预算对 4B 的目标步骤压制更强，且没有表现为更大的 held-out 标签破坏。忠实度方面，4B 的 FF-HARD 仅高 0.55 点 (8.47% 对 7.92%)，但步骤级翻转高 2.33 点 (7.01% 对 4.68%)。因此可得出的结论较窄：4B 在本设置中更容易被步骤遗忘干预推动，但较强 efficacy 并未转化为大幅更高的问题级硬忠实度。




图 1: 统一使用前 5 个 unlearning epoch 时的比较。绿色柱为 $n = 220, E = 10$ 运行截取至 epoch 5 的辅助点, 并非与两组 $n = 250$ 完全相同的模型规模对照。

两种模型的 $n = 250$ 目标题 ID 完全重合, 但各模型生成的 CoT 及切分步骤并不相同。进一步仅保留两者都满足论文初始预测一致条件的 158 道题, 可以减少可比子集不同造成的偏差。

表 3: 两种模型在共同初始可比题目上的比较。CoT 文本由各自模型生成, 故不是相同步骤的逐步配对。

模型	共同可比题	FF-HARD(1-5)	FF-HARD(E5)	Max FF-SOFT
Qwen3-8B	158	6.96%	6.33%	6.58
Qwen3-4B	158	7.59%	6.96%	6.58

共同可比题上, 4B 的 1-5 epoch FF-HARD 仅比 8B 高 0.63 点, Max FF-SOFT 近乎相同。这再次提示: 本次 4B/8B 的主要显著差异在干预有效性 Eff, 而不是有力的忠实度排序结论。

4 重点分析：4B 十轮扩展干预

表 4 使用每份文件的最终 checkpoint, 因此能复现既有 8B 摘要中的 endpoint 数值 (Eff = 71.50, Spec = 96.84, 全量 FF-HARD = 9.13%)。该表也使 $n = 220$ 的十轮终点不会被悄悄当作五轮结果。

表 4: 各结果文件最终 checkpoint 的 endpoint 汇总; 此口径与既有 8B 摘要的最终态统计一致。

实验	终点 E	Eff	Spec	FF-HARD(all)	FF-HARD(agree)	Mean soft
Qwen3-8B ($n = 250$)	5	71.50	96.84	9.13%	6.93%	3.36
Qwen3-4B ($n = 250$)	5	81.50	98.56	9.57%	7.91%	4.38
Qwen3-4B ($n = 220$)	10	90.25	98.04	12.00%	10.39%	6.08

对同一个 4B, $n = 220$ 运行进行内部比较, epoch 5 到 epoch 10 的变化为:

	Eff	Spec	FF-HARD(all)	FF-HARD(agree)	Mean soft
E5	88.99	97.84	11.00%	9.74%	5.42
E10	90.25	98.04	12.00%	10.39%	6.08
Δ	+1.26	+0.20	+1.00	+0.65	+0.66

延长更新确实进一步降低目标步骤概率并增加答案变化证据; 不过收益在约 epoch 6 后已趋于饱和, 且 FF-HARD 会随 epoch 小幅波动 (例如全量终点指标在 epoch 6-7 达到 12.50%, epoch 10 为 12.00%)。这正是报告完整轨迹而非只挑选最高终点的原因。




图 2: 每个 checkpoint 的终点式指标轨迹。虚线表示原论文与两组标准运行的 epoch 5 预算；绿色曲线右侧部分只属于 4B 扩展干预。




图 3: 各文件最终 checkpoint 的步骤级 FF-SOFT 分布。十轮组显示出更多向右侧（从初始答案移出概率质量）的步骤，但该变化同时受样本集合和 epoch 预算影响。

5 结论与限制

本次 C-Eval 中文复现提供了三点结论。第一，三份输出均完成并具备高 specificity（各比较口径约为 96.8–98.6），因而答案翻转不是明显的整体模型破坏所致。第二，在相同 $n = 250, E = 5$ 配置下，Qwen3-4B 的目标步骤更容易被 NPO+KL 压低，但其 FF-HARD 仅略高于 Qwen3-8B；不能据此宣称小模型的 CoT 显著更忠实。第三，也是本报告最重要的配置辨析： $n = 220$ 的 4B 结果实施了 10 个 epoch，延长干预确实提升 Eff、软变化和硬翻转率；该组应视作 epoch 强度扩展实验，不能直接并入标准模型排名。

本分析仍有局限：它只覆盖 C-Eval 一个中文题库与单个学习率；没有运行原论文用于宽泛能力保持控制的 MMLU “Gen” 评估；中文实现禁用了原文的英语 content-word POS 过滤；两个模型生成的 CoT 步骤不同，因此共同题目的比较也不是同一推理文本上的严格配对因果实验。这些限制不影响三份输出的内部统计，但限制了与原论文绝对数值以及模型规模因果效应的直接外推。

参考文献

1. Martin Tutek, et al. *Measuring Chain of Thought Faithfulness by Unlearning Reasoning Steps*. EMNLP 2025. <https://aclanthology.org/2025.emnlp-main.504/>
2. C-Eval: A Multi-Level Multi-Discipline Chinese Evaluation Suite for Foundation Models. <https://cevalbenchmark.com/>