

# 以 DeepSeek 修订思维链进行一次 SFT 后的 LLaMA-3B 参数忠实性分析报告

基于 Parametric Faithfulness FUR 协议的扩展实验

2026 年 5 月 27 日

## 摘要

本报告考察一个受资源与周期约束的扩展实验：使用 `deepseek-v4-pro` 修订 LLaMA-3B 在 Open-BookQA 上产生的思维链 (Chain-of-Thought, CoT)，随后进行一次 LoRA-SFT，并按照 Tutek 等人提出的通过遗忘推理步骤评测忠实性 (Faithfulness by Unlearning Reasoning Steps, FUR) 协议评估参数忠实性。SFT 后，Direct/CoT 准确率分别从 70.00%/73.00% 变化到 73.00%/77.00%，平均 CoT 步数由 6.37 降为 3.12。FUR 的控制指标 Efficacy 与 Specificity 分别由 92.58%/94.04% 升至 97.62%/98.79%。然而，在双方均满足 Direct-CoT 一致性的 75 道严格配对题上，FF-HARD 改变量为  $-4.00$  百分点 (95% bootstrap CI  $[-16.00, 8.00]$ )，FF-SOFT 改变量为  $+1.12$  百分点 (95% bootstrap CI  $[-7.95, 9.95]$ )。因此，本实验支持“蒸馏 SFT 令推理更紧凑、FUR 干预更有效且更局部”，但尚不足以确认参数忠实性获得稳定提升。

## 1 研究问题与评价逻辑

Tutek 等人 [1] 指出，语言模型生成的解释可能与其参数中实际支持答案的知识不一致。该论文以 FUR 对某个 CoT 步骤表达的事实进行定向遗忘：若移除该事实会导致原答案概率下降或答案翻转，并且对保留题影响有限，则该 CoT 步骤更可能反映了模型真实使用的参数知识。本实验在相同问题上比较未经训练的 Base 模型与仅接受一次 Teacher-CoT SFT 的模型，研究以下问题：

1. 蒸馏式 SFT 是否改善任务能力以及 Direct 答案与 CoT 答案的一致性；
2. SFT 是否使 FUR 的干预具备足够高的有效性与特异性；
3. 在排除模型答案不一致造成的混淆后，参数忠实性指标是否提高。

令  $p_0(y)$  表示遗忘前原预测选项的概率， $p_e(y)$  表示对某一 CoT 步骤执行第  $e$  个遗忘 epoch 后该选项的概率。本文沿用论文中的两类忠实性结果：

$$\text{FF-SOFT}(q) = \max_{s,e} [p_0(y_q) - p_{s,e}(y_q)] \times 100, \quad (1)$$

$$\text{FF-HARD}(q) = \mathbb{I} \left[ \exists s, e : \arg \max_y p_{s,e}(y) \neq \arg \max_y p_0(y) \right] \times 100. \quad (2)$$

其中  $s$  为 CoT 的可遗忘步骤。FF-SOFT 衡量原答案概率可被移除的幅度，FF-HARD 衡量是否最终越过决策边界。按照原协议，主要忠实性结果优先报告 Direct 答案与 CoT 答案一致的问题，以免对一条并未解释原始答案的 CoT 进行不合理归因。

遗忘是否可解释还取决于两个控制指标。Efficacy 测量目标 CoT 步骤在遗忘后的对数概率下降程度；Specificity 测量保留题上的初始预测是否保持不变。高 Efficacy 与高 Specificity 表明干预确实移除了目标信息，而不是造成广泛模型退化。

2 实验设置与完整性审计

表 1: 实验及训练设置

| 项目        | 设置                                                      |
|-----------|---------------------------------------------------------|
| 基础模型      | Llama-3.2-3B-Instruct                                   |
| Teacher   | deepseek-v4-pro (thinking=high)                         |
| 训练数据      | OpenBookQA train; 2000 drafts; 1852 accepted revisions  |
| SFT 方法    | LoRA, target=down_proj, rank=32, alpha=64, dropout=0.05 |
| SFT 超参数   | lr=1e-4; epoch=1; batch=2; grad_acc=16; max_len=512     |
| FUR 测试集   | OpenBookQA test: 100 target + 20 retain; seed=1001      |
| FUR 超参数   | NPO+KL; lr=3e-5; epoch=5; beta=0.1; KL=1.0              |
| FUR 可训练参数 | mlp.down_proj.weight only                               |

训练阶段使用 OpenBookQA 训练集中的 2000 个问题。Base LLaMA-3B 首先生成学生草稿；Teacher 仅对草稿进行修订并提供可监督的简洁推理，经过正确答案、格式、答案泄漏以及句数/长度规则过滤后进入 SFT。评估完全独立于训练样本：在 OpenBookQA test 中固定抽取 100 道目标题和 20 道保留题，Base 与 SFT 模型使用同一题目与同一 FUR 超参数。

表 2: 正式实验产物完整性审计

| 产物                   | 预期行数 | 观测行数 | 检查   |
|----------------------|------|------|------|
| Student drafts       | 2000 | 2000 | PASS |
| Teacher revisions    | 2000 | 2000 | PASS |
| Accepted SFT records | 1852 | 1852 | PASS |
| Base evaluation CoTs | 120  | 120  | PASS |
| SFT evaluation CoTs  | 120  | 120  | PASS |
| Base valid FUR steps | 495  | 495  | PASS |
| SFT valid FUR steps  | 311  | 311  | PASS |

表 2 显示所有预期输出均完整写入；Base 与 SFT 的有效 FUR 步骤数不同并非缺失数据，而是因为 SFT 生成的 CoT 本身更短，从而通过可遗忘步骤过滤的步骤更少。统计脚本逐题读取原始 JSONL，并对每个有效步骤的 5 个遗忘 epoch 重新计算全部指标。

3 蒸馏数据质量

表 3: Teacher 修订数据质量过滤结果

| 过滤状态                 | 数量   | 占比 (%) |
|----------------------|------|--------|
| accepted             | 1852 | 92.60  |
| wrong_teacher_answer | 88   | 4.40   |
| invalid_json         | 35   | 1.75   |
| answer_leak          | 13   | 0.65   |
| sentence_count       | 10   | 0.50   |
| rationale_length     | 2    | 0.10   |

Teacher 修订的接受率为 92.60%，说明生成管线能以较低废弃率形成训练数据。最主要的拒绝原因为 Teacher 最终答案不正确（4.40%），这是必须排除的噪声：将错误的解释用于 SFT 会同时污染答案能力和后续忠实性解释。JSON 格式失败及答案泄漏分别仅占 1.75% 和 0.65%，表明结构化输出与防止 CoT 直接暴露选择标签的过滤发挥了作用。最终 1852 条样本用于一次 SFT，因此实验测量的是“正确且受约束的 Teacher 推理”的影响，而不是无筛选大模型回答的影响。




图 1: Teacher 修订样本的过滤审计。高接受率保证 SFT 训练规模，而对错误答案和泄漏样本的剔除降低了将教师伪相关模式写入模型的风险。

4 任务能力与思维链形态

表 4: 答案表现与 CoT 形态

| 模型   | Direct Acc. | CoT Acc. | D/C Agree | 平均步骤 | 平均词数  |
|------|-------------|----------|-----------|------|-------|
| Base | 70.00       | 73.00    | 82.00     | 6.37 | 81.33 |
| SFT  | 73.00       | 77.00    | 85.00     | 3.12 | 40.49 |

SFT 后 Direct 准确率上升 3.00 百分点，CoT 准确率上升 4.00 百分点，Direct-CoT 一致率上升 3.00 百分点。由于仅有 100 道目标题，这些能力提升在配对检验中尚不能视为确定性结论（见表 8），但其方向与 Teacher 提供更规范推理的训练目标相符。

更明确的效应来自 CoT 形态：平均步骤减少 3.25 步，平均词数减少 40.84 词，配对 bootstrap 置信区间均不跨越零。Teacher 修订将冗长或重复的学生解释压缩为较短的推理路径，使得 FUR 可干预步骤由 Base 的 495 个降至 SFT 的 311 个。这一现象有双重含义：较短 CoT 便于定位单条事实，也可能将多个证据压入同一稳定步骤，改变 FF-HARD 越过决策边界的机会。





图 2: Base 与 SFT 模型生成 CoT 的步骤数与词数分布。SFT 主要可观察变化是推理长度系统性收缩。

## 5 FUR 控制有效性

表 5: FUR 有效性与特异性控制指标

| 模型   | 有效步骤 | Efficacy | Efficacy@5 | Specificity | Specificity@5 |
|------|------|----------|------------|-------------|---------------|
| Base | 495  | 92.58    | 96.69      | 94.04       | 92.64         |
| SFT  | 311  | 97.62    | 99.44      | 98.79       | 98.25         |



(a) 论文式 Efficacy–Specificity 控制图。点面积编码 FF-HARD。

(b) 随遗忘 epoch 变化的控制轨迹。

图 3: FUR 干预的有效性与特异性。SFT 点同时向右上方移动, 并在各 epoch 保持更高 Specificity, 说明定向遗忘在该模型上更容易成功且副作用更小。

Base 的平均 Specificity 为 94.04%, 低于图 3a 所示的 95% 参考线; SFT 达到 98.79%, 同时 Efficacy 达到 97.62%。这说明 SFT 之后观察到的忠实性信号具有更好的干预控制基础: 目标步骤的概率能够被明显降低, 而保留题预测大多不受扰动。一个需谨慎对待的机制解释是, 本实验的 SFT LoRA 与 FUR 均作用于 `down_proj` 相关参数, SFT 可能提高了该参数子空间对遗忘优化的响应性。因此, 更高控制指标证明本次 FUR 更可靠, 并不单独等价于模型内部推理机制更真实。

## 6 参数忠实性结果

表 6: FUR 参数忠实性主要结果

| 模型   | Agree N | FF-HARD Agree | FF-SOFT Agree | FF-HARD All | FF-SOFT All |
|------|---------|---------------|---------------|-------------|-------------|
| Base | 82      | 70.73         | 54.09         | 72.00       | 51.97       |
| SFT  | 85      | 65.88         | 56.07         | 67.00       | 52.87       |

表 7: SFT 相对于 Base 的指标变化

| 指标            | Base  | SFT   | SFT - Base |
|---------------|-------|-------|------------|
| Direct Acc.   | 70.00 | 73.00 | +3.00      |
| CoT Acc.      | 73.00 | 77.00 | +4.00      |
| D/C Agree     | 82.00 | 85.00 | +3.00      |
| 平均步骤          | 6.37  | 3.12  | -3.25      |
| 平均词数          | 81.33 | 40.49 | -40.84     |
| Efficacy      | 92.58 | 97.62 | +5.05      |
| Specificity   | 94.04 | 98.79 | +4.76      |
| FF-HARD Agree | 70.73 | 65.88 | -4.85      |
| FF-SOFT Agree | 54.09 | 56.07 | +1.98      |




图 4: 忠实性指标比较。FF-HARD 与 FF-SOFT 给出不同方向的结果, 提示不可仅凭单一指标声称 SFT 已提升参数忠实性。

在论文协议的各自一致题口径下, SFT 的 FF-SOFT 由 54.09% 上升至 56.07%, 但 FF-HARD 由 70.73% 降至 65.88%。两者并不矛盾: FF-SOFT 只要求原答案概率发生下降; FF-HARD 还要求下降量足以越过最大概率的决策边界。本实验中, SFT 在共同一致题上的初始预测 margin 平均增加 9.30 百分点, 说明即便可移除的概率质量略有增加, 更稳定的初始答案仍可能减少最终翻转数量。

另一个解释来自 CoT 压缩。较少步骤减少了“至少存在一个步骤引发答案翻转”这一事件的尝试次数, 从而可能机械性压低 FF-HARD; 与此同时, 更集中步骤仍能引起较大的概率下降。因此, 比较不同长度 CoT 时, FF-SOFT 与控制图应与 FF-HARD 共同阅读。

## 7 配对统计分析

各模型自己的 Direct-CoT 一致题数量不同 (Base 为 82, SFT 为 85), 直接对这两个分母做差会混入样本组成变化。为提高可比性, 本报告预先将双方均一致的 75 道题作为严格配对子集, 并在同一题上计算 SFT 减 Base 的差值。连续指标使用 10,000 次配对 bootstrap 得到 95% 百分位置信区间; 二元指标另外使用双侧 exact McNemar 检验, 其中 “+/-” 表示 SFT 相对 Base 的改善题数/退化题数。

表 8: 严格配对比较及 95% bootstrap 置信区间

| 指标                            | N   | Base  | SFT   | 差值 [95% CI]             | McNemar (+/-; p) |
|-------------------------------|-----|-------|-------|-------------------------|------------------|
| Direct accuracy               | 100 | 70.00 | 73.00 | +3.00 [-3.00, 9.00]     | 6/3; p=0.508     |
| CoT accuracy                  | 100 | 73.00 | 77.00 | +4.00 [-3.00, 11.00]    | 8/4; p=0.388     |
| Direct-CoT agreement          | 100 | 82.00 | 85.00 | +3.00 [-5.00, 11.00]    | 10/7; p=0.629    |
| CoT steps                     | 100 | 6.37  | 3.12  | -3.25 [-3.83, -2.72]    | -                |
| CoT words                     | 100 | 81.33 | 40.49 | -40.84 [-45.50, -35.93] | -                |
| FF-HARD (common agree)        | 75  | 68.00 | 64.00 | -4.00 [-16.00, 8.00]    | 10/13; p=0.678   |
| FF-SOFT (common agree)        | 75  | 54.49 | 55.61 | +1.12 [-7.95, 9.95]     | -                |
| Initial margin (common agree) | 75  | 73.18 | 82.49 | +9.30 [5.34, 13.38]     | -                |

配对结果包含三点专业判断：

1. CoT 步数与词数的收缩具有清晰区间证据，可视为本次 SFT 的稳定行为改变；
2. FF-HARD 在共同一致题上降低 4.00 百分点，但置信区间  $[-16.00, 8.00]$  跨零，McNemar  $p = 0.678$ ，不能认为存在稳定恶化或改善；
3. FF-SOFT 增加 1.12 百分点，区间  $[-7.95, 9.95]$  同样跨零；相比之下，初始 margin 的显著增加解释了为何软概率变化未转化为更多硬翻转。

## 8 结论、限制与后续检验

本次一次性 SFT 已实现一个完整且可复查的实验闭环：Teacher 修订数据经质量过滤，SFT 后模型在相同测试题上接受与 Base 完全对应的 FUR 评估，原始逐步骤结果、统计表格以及矢量图均已保留。从观测数据看，蒸馏 CoT SFT 最确定的作用是生成更短、更集中且更易被局部干预的推理；它同时使 FUR 的 Efficacy 与 Specificity 进入更理想范围。对于核心问题“参数忠实性是否提升”，FF-HARD 与 FF-SOFT 的配对证据尚不充分，应报告为未确认，而非正面结论。

本结论受到以下限制。第一，仅有一个随机种子和 100 道目标题，统计功效有限。第二，尚无使用学生原始 CoT 进行 SFT 的对照臂，不能将 Teacher 质量效应与一般 SFT 效应分离。第三，训练适配器与 FUR 干预都集中于 `down_proj`，这会强化“可被遗忘”与“真实支持答案”之间的混淆。第四，本轮只覆盖 OpenBookQA，尚未检验跨数据集迁移。

在后续计算预算允许时，最关键的补充不是立即扩展更复杂的 RL，而是增加两组控制：同规模原始学生 CoT-SFT 与答案正确但不含详细推理的 SFT，并在 ARC-Challenge 上复用相同 FUR 协议。这样能够判断当前的控制性改善究竟来源于 Teacher 推理结构，还是仅来源于训练与干预参数空间的一致性。

## 参考文献

- [1] Tutek, M., Chaleshtori, F. H., Marasović, A., & Belinkov, Y. Measuring Chain of Thought Faithfulness by Unlearning Reasoning Steps. arXiv:2502.14829, 2025. <https://arxiv.org/abs/2502.14829>.